Random Forest

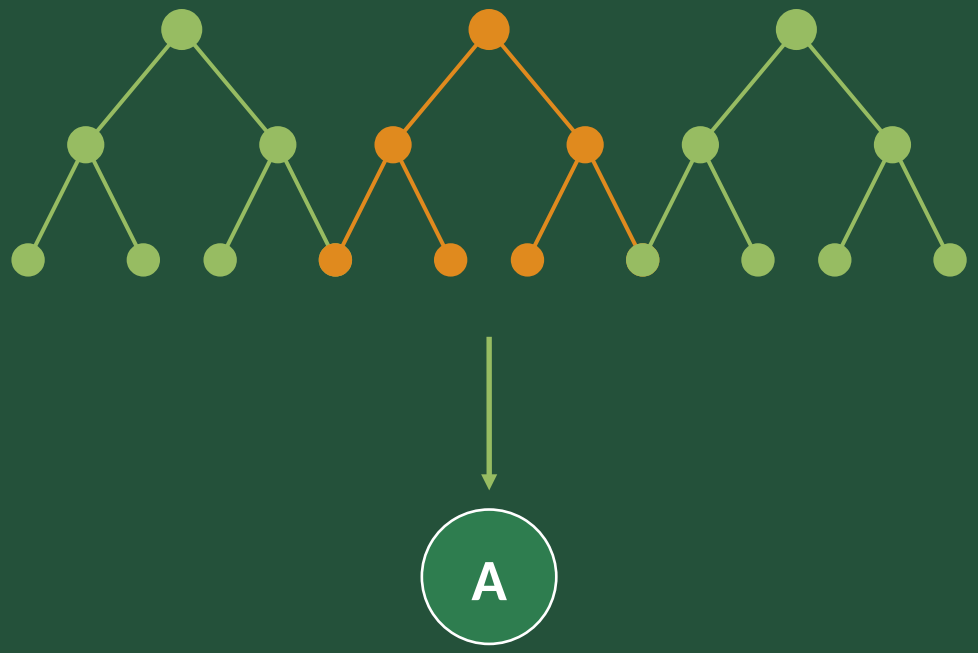
Дослідження методу машинного навчання

Класифікація · Регресія

Автор: Бондар Р.Р.

Навчальний заклад: МНАУ

Дисципліна: Інтелектуальний аналіз даних



дерева голосують — ліс вирішує

Багато дерев голосують краще за одне

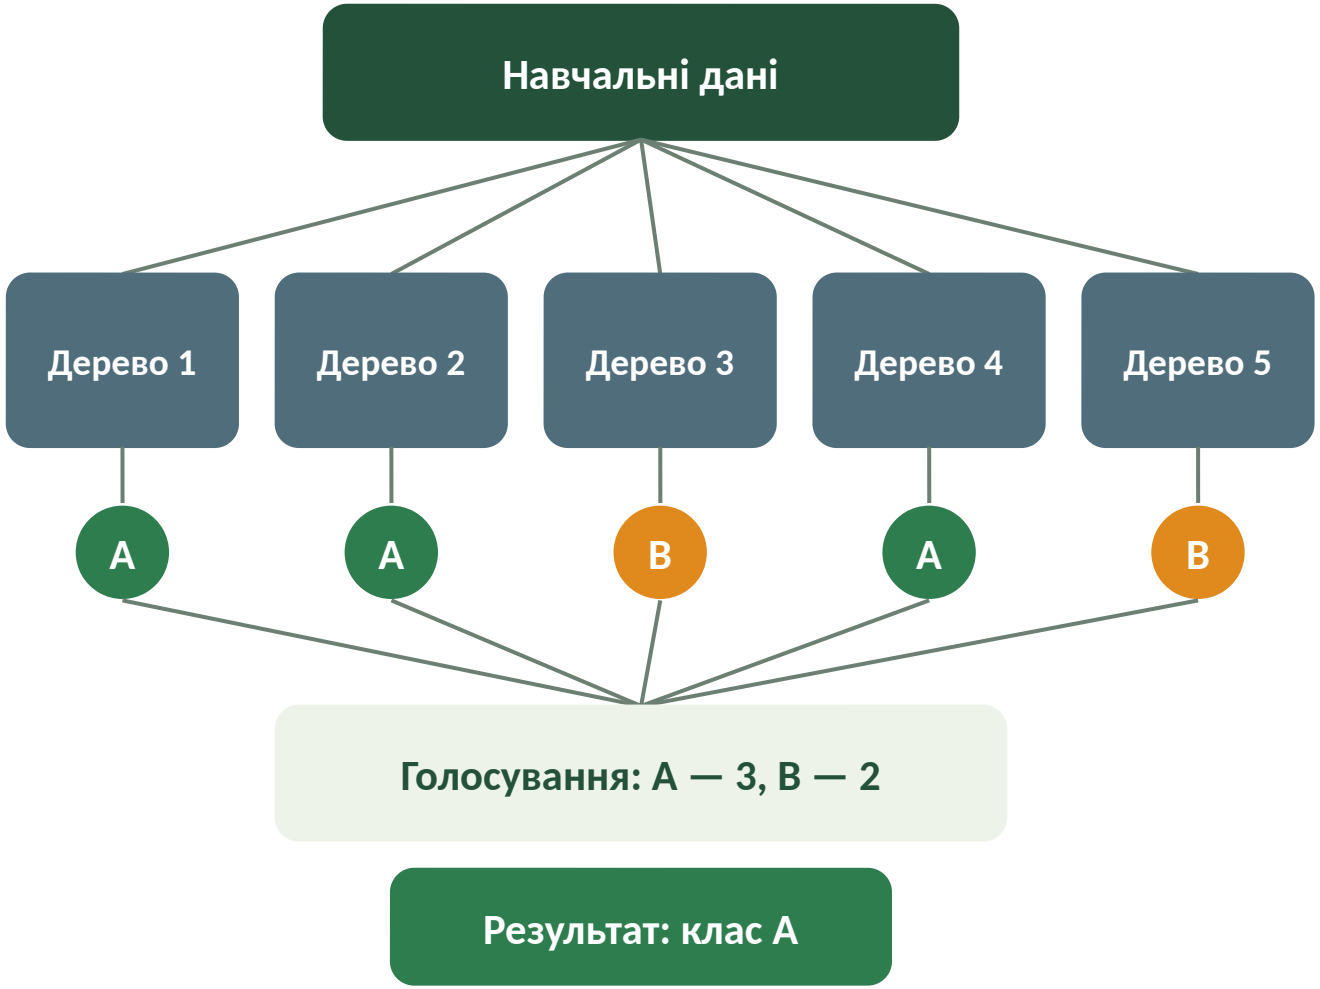
Приклад із життя

Обираєте фільм на вечір. Одна порада може бути випадковою. Питаєте п’ятьох друзів — і берете те, що назвала більшість.

Де тут «випадковість»?

Різні дані: кожне дерево вчиться на bootstrap-вибірці

Різні ознаки: на вузлі — лише випадкова частина ознак



Основна ідея: Breiman (2001), Machine Learning, 45(1), 5–32.

Математична основа

1 · Bootstrap

$$D_b = \{z_1, \ldots, z_n\},\ z_j \in D$$

D — навчальна вибірка з n об’єктів; D_b — вибірка для дерева b: n об’єктів «з поверненням». У неї потрапляє ≈63 % унікальних об’єктів.

2 · Випадкові ознаки

$$m \le p,\ \text{часто } m = \sqrt{p}$$

p — усі ознаки; m — скільки з них розглядається на кожному вузлі (параметр max_features).

3 · Критерій Gini

$$\text{Gini}(S) = 1 - \sum p_i^2$$

S — об’єкти у вузлі; p_i — частка класу i. 0 — «чистий» вузол. Альтернатива: ентропія $H(S) = -\sum p_i \log_2 p_i$.

4 · Голосування

$$\hat{y} = \text{mode}(T_1(x), \ldots, T_n(x))$$

$T_i(x)$ — клас від i-го дерева для об’єкта x; n — число дерев. Регресія: $\hat{y} = (1/n) \sum T_i(x)$.

Джерела: Breiman (2001); scikit-learn — RandomForestClassifier та Decision Trees (Mathematical formulation).

Алгоритм: від даних до передбачення

1

Вихідний датасет

n об’єктів, p ознак, відомі класи

2

Bootstrap-вибірки

для кожного дерева — своя вибірка з поверненням

3

Побудова дерев

кожне дерево росте на власній вибірці

4

Випадкові ознаки

на вузлі розглядаємо m із p ознак

5

Навчання дерев

розбиття з найкращим Gini; дерева незалежні

6

Прогноз дерев

новий об’єкт x проходить кожне дерево

7

Голосування

класифікація — більшість; регресія — середнє

8

Результат

підсумковий клас або число ŷ

навчання (кроки 1–5)

передбачення (кроки 6–8)

Джерела: Breiman (2001); scikit-learn Ensemble methods — Forests of randomized trees.

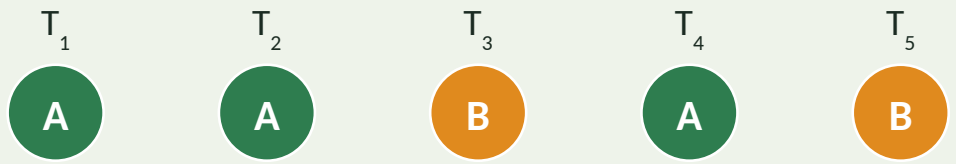
Гіперпараметри scikit-learn

Параметр	Що робить	Вплив при збільшенні / зміні	З чого почати
`n_estimators`	Кількість дерев	Стабільніше, але довше навчання; ефект насичується	100, далі збільшувати, поки CV не стабілізується
`max_depth`	Макс. глибина дерева	Складніша модель, ризик перенавчання	None, далі обмежувати (сітка за CV)
`max_features`	Ознак на вузол	Дерева схожіші, менше випадковості, повільніше	"sqrt" (класифікація), далі перебір
`min_samples_split`	Мін. об’єктів для поділу	Простіші дерева, менше перенавчання	2, далі збільшувати за CV
`min_samples_leaf`	Мін. об’єктів у листку	Гладша межа, ризик недонавчання	1, далі пробувати 3, 5, 10
`bootstrap`	Вибірка з поверненням	True — різноманіття дерев і OOB-оцінка	True (за замовчуванням)
`criterion`	Критерій розбиття	gini / entropy / log_loss — зазвичай близько	gini; порівняти з entropy
`random_state`	Зерно випадковості	Якість «в середньому» не змінює	Зафіксувати для відтворюваності

Джерело: scikit-learn — RandomForestClassifier (документація). Значення не є універсально оптимальними.

Числовий приклад: голосування і Gini

Голосування п’яти дерев



A: 3 голоси

B: 2 голоси

$$\hat{y} = \text{mode}(A, A, B, A, B) = A$$

Gini для вузла: 3 об’єкти A, 2 об’єкти B

$$pA = 3/5 = 0{,}6; \quad pB = 2/5 = 0{,}4$$

$$\text{Gini} = 1 - (0{,}6^2 + 0{,}4^2)$$

$$\text{Gini} = 1 - (0{,}36 + 0{,}16) = 0{,}48$$

Чистий вузол: Gini = 0. Для двох класів максимум — 0,5 (50/50). Ентропія цього вузла: $H = -(0{,}6 \cdot \log_2 0{,}6 + 0{,}4 \cdot \log_2 0{,}4) \approx 0{,}971$.

Дерево обирає розбиття, що найбільше зменшує Gini у вузлі. Єдиної глобальної функції втрат для всього лісу немає.

Джерела: scikit-learn — Decision Trees (Mathematical formulation); Breiman (2001).

Практичний експеримент

300 × 2

об’єктів × ознак (Температура, Вібрація); класи 60/40; 5 % шуму в мітках

75 / 25

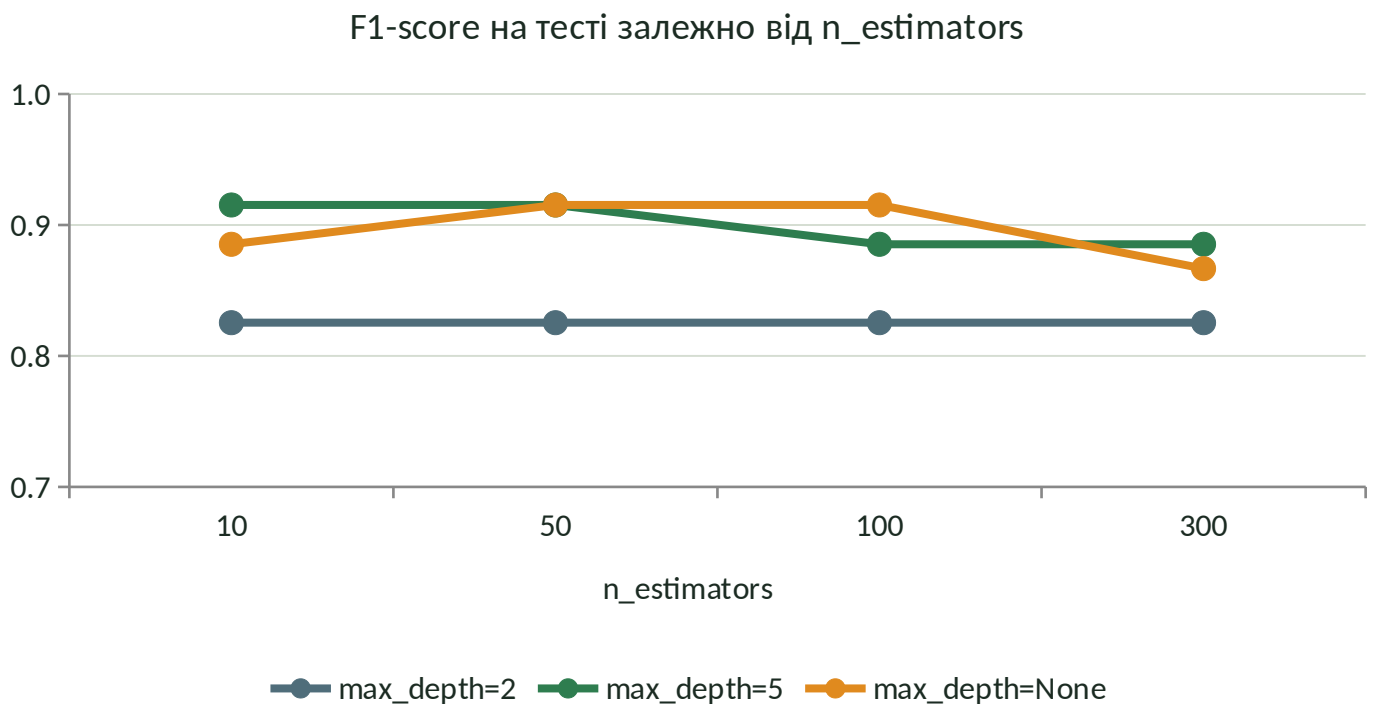
train / test, stratify=y, random_state=42 (225 і 75 об’єктів)

5 метрик

Accuracy, Precision, Recall, F1, ROC-AUC

12 конфіг.

n_estimators {10, 50, 100, 300} × max_depth {2, 5, None}



RF, 100 дерев: accuracy 0,933 · F1 0,915 · AUC 0,952

Тест — 75 об’єктів; різниці між налаштуваннями — у межах шуму. Дані синтетичні.

Результати отримано запуском random_forest_experiment.ipynb (scikit-learn 1.8.0).

Переваги та обмеження

Переваги

- \+ Висока якість на табличних даних без складного налаштування
- \+ Менше перенавчається, ніж одне дерево
- \+ Ловить нелінійні залежності та взаємодії ознак
- \+ Масштабування ознак не потрібне
- \+ Дає оцінку важливості ознак (з обмеженнями)

Обмеження

- ! Важче пояснити окреме рішення, ніж у одного дерева
- ! Більше пам’яті й часу, ніж у одного дерева
- ! Категорії треба кодувати; NaN підтримуються з версії 1.4 — якість перевіряйте
- ! У регресії не виходить за межі навчальних значень
- ! На дуже розріджених великих просторах ознак (текст) може поступатися лінійним

Джерела: scikit-learn — RandomForestClassifier (підтримка NaN), Ensemble methods; Breiman (2001).

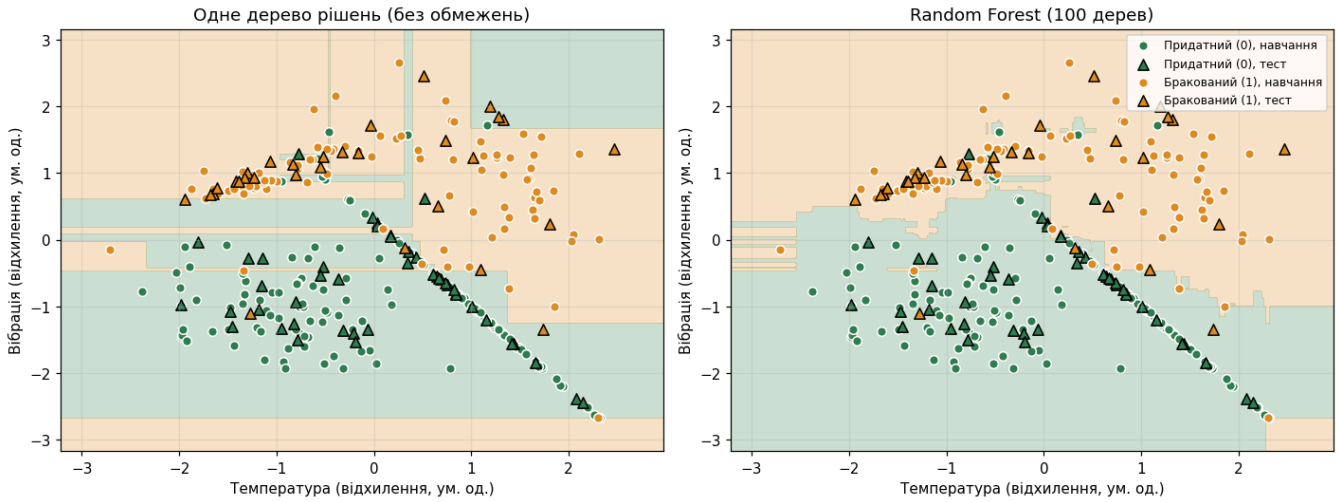
Random Forest, Decision Tree і Gradient Boosting

Критерій	Decision Tree	Random Forest	Gradient Boosting
Принцип	Одне дерево, послідовні розбиття	Багато незалежних дерев; голосування	Дерева послідовно виправляють помилки попередніх
Якість (табличні дані)	Помірна, нестабільна	Зазвичай висока «з коробки»	Часто найвища після налаштування
Перенавчання	Високий ризик без обмежень	Нижчий завдяки усередненню	Вищий; потрібна регуляризація
Швидкість навчання	Дуже швидко	Швидко; дерева незалежні	Повільніше: навчання послідовне
Інтерпретованість	Висока	Низька (важливість ознак)	Низька
Головне	Простота й наочність	Надійний базовий вибір	Точність, чутливість до параметрів

У нашому експерименті (параметри за замовчуванням, тест 75 об’єктів) F1: DT 0,815 · RF 0,915 · GB 0,877. Повторна CV: різниця RF і GB менша за розкид.

Джерела: scikit-learn — Ensemble methods, DecisionTreeClassifier, GradientBoostingClassifier.

Висновки



0,933

accuracy RF

0,915

F1 RF

0,952

ROC-AUC RF

Праворуч — Random Forest: межа гладша, ніж у одного дерева.

Що показав експеримент

RF краще за одне дерево (F1 0,915 проти 0,815); після 50–100 дерев приріст зникає; depth=2 недонавчається.

Коли доцільно

Табличні дані, нелінійні залежності, потрібна надійна базова модель без тонкого налаштування.

Обмеження

Малий тест і синтетичні дані; RF ≈ GB у межах шуму; складніше пояснити окреме рішення.

Результати: random_forest_experiment.ipynb. Нотатка: scikit-learn обирає клас за найбільшою середньою ймовірністю дерев.

Джерела

Джерело	Що підтверджує
Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32. DOI: 10.1023/A:1010933404324	Історія методу; bagging + випадкові ознаки; голосування
scikit-learn: RandomForestClassifier. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html	Гіперпараметри, значення за замовчуванням, predict/predict_proba, NaN
scikit-learn: Ensembles. https://scikit-learn.org/stable/modules/ensemble.html	Ліс, bootstrap, важливість ознак; порівняння з boosting
scikit-learn: Decision Trees. https://scikit-learn.org/stable/modules/tree.html	Gini, ентропія, критерії розбиття
scikit-learn: GradientBoostingClassifier. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingClassifier.html	Опис градієнтного бустингу для порівняння
Hastie, T., Tibshirani, R., Friedman, J. (2009). The Elements of Statistical Learning, 2nd ed., Springer, розділ 15 «Random Forests»	Додаткове пояснення теорії